

# Elasticsearch - Eine Einführung

Till Hildebrandt, Frederik Schnoege, Tobias Jansing



elasticsearch

# Elasticsearch Allgemein

# Was ist Elasticsearch?

- Verteilte Suchmaschine und Analytics-Engine
- Speicherung von Dokumenten im JSON-Format
- REST-API
- Xing, GitHub, Stackoverflow...



# Was ist Elasticsearch?

## Besonderheiten

Datenverteilung durch  
Sharding auf Clustern

Automat. Replikation

Verteilte Suchfunktion

Analytics (Kibana,  
Logstash)

## Ziele

Verfügbarkeit

Performanz

Skalierbarkeit

Ausfallsicherheit

Lastverteilung

## Vorteile

Nahezu-Echtzeit-Suche

Analytics

Geodaten + Score-Werte

Open Source

Viele Sprachen verfügbar



# Kibana

Apache - Total Visitors

4,931,584


Apache - Unique Visitors

29,740


Apache - Unique Visitors ...

City	Unique Visitors
Beijing	562
Redmond	445
Ashburn	400
Chicago	373
Los Angeles	245
Seattle	233
San Jose	232
Singapore	208


Apache - Bytes and Count



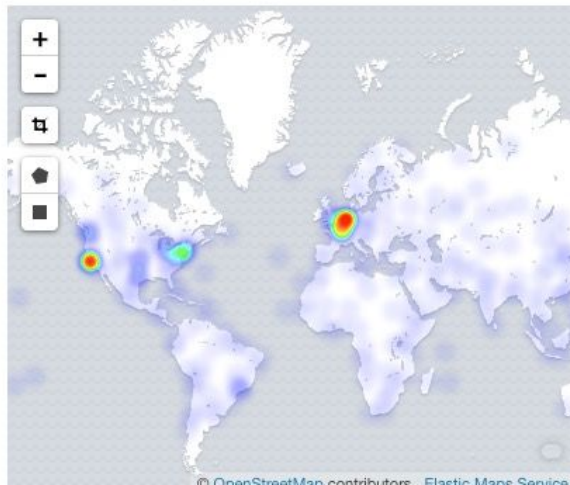
Apache - Country and Status




Apache - Country traffic by hour



Apache - Visitor Map (geocentroid)



Apache - Browser to Country (vega)





Dev Tools

Console

History

Settings

Help

- Discover
- Visualize
- Dashboard
- Graph
- Monitoring
- Timelion
- Management
- Dev Tools

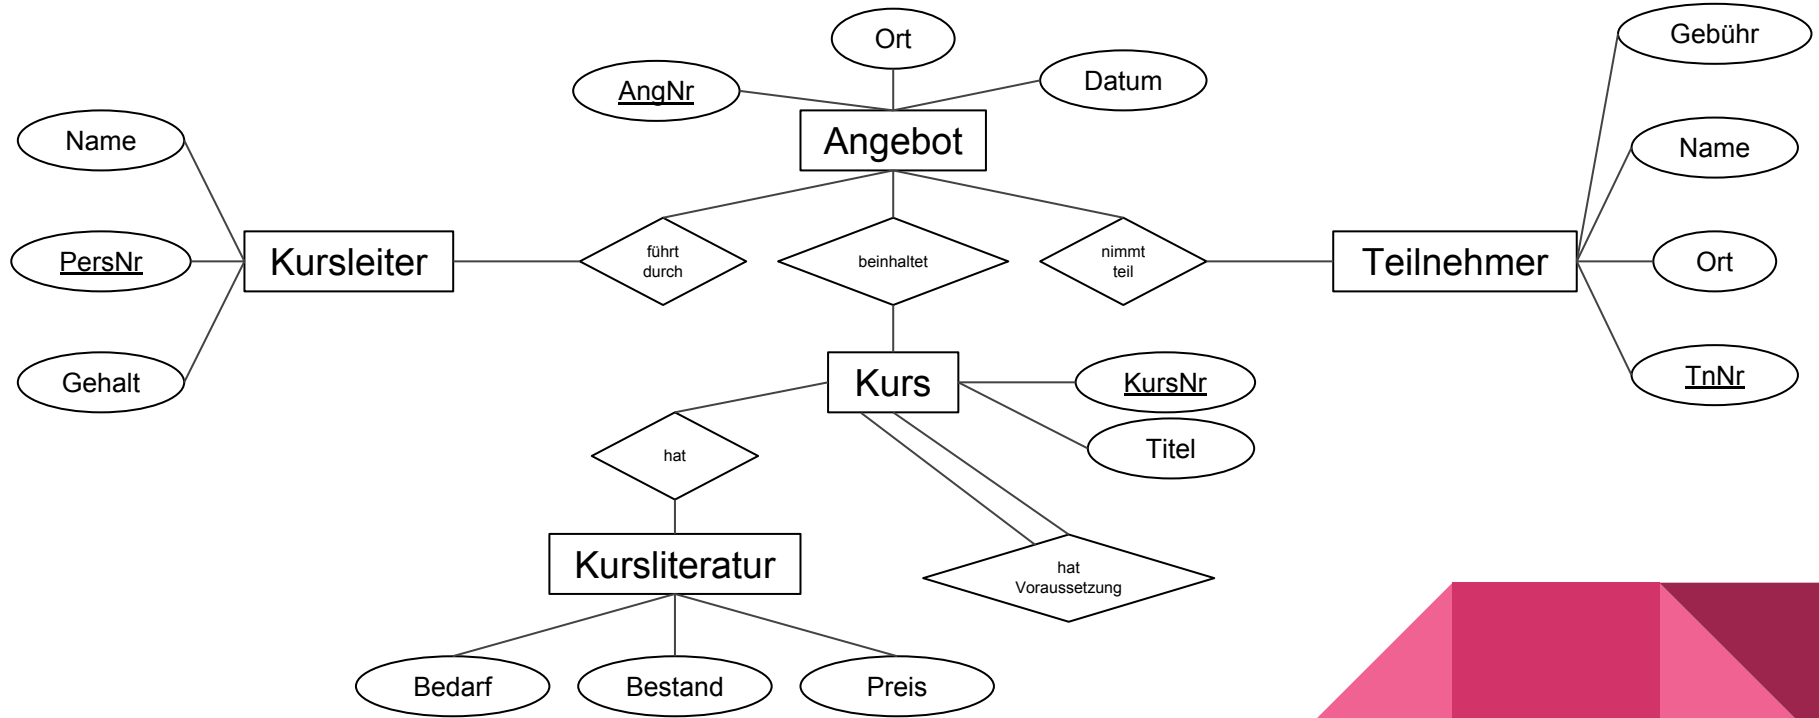
```
1 GET logstash-*/_search
2 {
3   "query": {
4     "term": {
5       "response": {
6         "value": 404
7       }
8     }
9   }
10 }
11
12 GET _template/apache_elk_example
13
14 DELETE apache_elk_example
15
16 PUT /_cluster/settings
17 {
18   "transient": {
19     "logger.org.elasticsearch.indices.breaker":
20       "TRACE"
21   }
22 }
```

```
1 {
2   "took": 5,
3   "timed_out": false,
4   "_shards": {
5     "total": 1,
6     "successful": 1,
7     "failed": 0
8   },
9   "hits": {
10     "total": 728,
11     "max_score": 2.9562535,
12     "hits": [
13       {
14         "_index": "logstash-0",
15         "_type": "apache",
16         "_id": "AVgBLm0Yr-RtFf5Q_4YS",
17         "_score": 2.9562535,
18         "_source": {
19           "index": "logstash-0",
20           "@timestamp": "2016-10-25T17:15:48.201Z",
21           "ip": "73.121.214.226",
22           "extension": "css",
23           "response": "404",
```

# ER-Modell



# ER-Modell



```

1 PUT_angebot
2 {
3   "settings": {
4     "number_of_shards": 1
5   },
6   "mappings": {
7     "_doc": {
8       "properties": {
9         "AngNr": {
10          "type": "keyword"
11        },
12        "Kurs": {
13          "type": "nested",
14          "properties": {
15            "KursNr": {
16              "type": "keyword"
17            },
18            "Titel": {
19              "type": "keyword"
20            },
21            "KursLit": {
22              "type": "nested",
23              "properties": {
24                "Bestand": {
25                  "type": "integer"
26                },
27                "Bedarf": {
28                  "type": "integer"
29                },
30                "Preis": {
31                  "type": "double"
32                }
33              }
34            },
35            "Voraus": {
36              "type": "nested",
37              "properties": {
38                "VorNr": {
39                  "type": "keyword"
40                }
41              }
42            }
43          }
44        },

```

```

45      "Datum": {
46        "type": "date",
47        "format": "dd.MM.yyyy"
48      },
49      "Ort": {
50        "type": "keyword"
51      },
52      "Kursleiter": {
53        "type": "nested",
54        "properties": {
55          "PersNr": {
56            "type": "keyword"
57          },
58          "Name": {
59            "type": "keyword"
60          },
61          "Gehalt": {
62            "type": "double"
63          }
64        }
65      },
66      "Teilnehmer": {
67        "type": "nested",
68        "properties": {
69          "TnNr": {
70            "type": "keyword"
71          },
72          "Name": {
73            "type": "keyword"
74          },
75          "Ort": {
76            "type": "keyword"
77          },
78          "Gebuehr": {
79            "type": "double",
80            "null_value": 0
81          }
82        }
83      }
84    }
85  }
86 }
87 }

```

# Queries

```
GET /angebot/_search?filter_path=aggregations.0rte.buckets.key
{
  "aggs" : {
    "0rte" : {
      "terms" : {
        "field" : "0rt"
      }
    }
  }
}
```

```
POST /angebot/_update_by_query
{
  "query": {
    "bool": {
      "must": {
        "match": {
          "0rt": "Kiel"
        }
      }
    }
  },
  "script": "ctx._source.0rt = 'Lübeck'"
}
```

GET /angebot/\_search?filter\_path=aggregations.\*.\*.buckets.key,aggregations.\*.\*.buckets.Vorauscount.value

```
{
  "aggs": {
    "Kurs.Titel": {
      "nested": {
        "path": "Kurs"
      },
      "aggs": {
        "Kurs.Titel": {
          "terms": {
            "field": "Kurs.Titel"
          },
          "aggs": {
            "Vorauscount": {
              "bucket_script": {
                "buckets_path": {
                  "vCnt": "Kurs.Voraus._count",
                  "kCnt": "_count"
                },
                "script": "params.vCnt / params.kCnt"
              }
            },
            "Kurs.Voraus": {
              "nested": {
                "path": "Kurs.Voraus"
              }
            }
          },
          "voraus_bucket_filter": {
            "bucket_selector": {
              "buckets_path": {
                "vCnt": "Kurs.Voraus._count",
                "kCnt": "_count"
              },
              "script": "params.vCnt / params.kCnt >= 2"
            }
          }
        }
      }
    }
  }
}
```



# Fazit, Erfahrungen und Probleme

# Erfahrungen und Probleme

- Fehlende SQL-Standardfeatures
  - Fehlende Joins → verkompliziert Datenstruktur
  - Daten manipulieren, formatierte Ausgaben etc. schwierig
  - Direkte Umwandlung von SQL-Befehlen in Elastic-Befehle nicht einfach möglich
  - Keine Subqueries, Speicherung der Resultate einzelner Queries nötig
- Doppelte Datenhaltung notwendig, obwohl nicht angestrebt
- Keine Tabellen sondern Objekte → völlig andere Verwendung



# Fazit

- Daten ungeeignet für Elasticsearch
  - Konzipiert für unstrukturierte Daten, keine Normalisierung der Daten
  - Fehlende SQL-Features bzw. andere Architektur verkomplizieren Übergang
  - Filter, Aggregationen etc. teils sehr kompliziert und unübersichtlich
- Geeignet eher für das Speichern und Abfragen von Dokumenten
  - Elastic-Prinzip: Wegschreiben und bei Bedarf alles Abfragen
  - Verknüpfung von Informationen aus unterschiedlichen Dokumenten schwierig
- SQL-Denkweise muss angepasst werden
- Elastic ist schnell







Noch Fragen?